Министерство образования Республики Беларусь

Учреждение образования БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ ИНФОРМАТИКИ И РАДИОЭЛЕКТРОНИКИ

Факультет	Компьютерных Систем и Сетей
Кафедра	Информатики
	ОТЧЁТ
	по лаборатоной работе №3 по теме
Применение программных средств машинного обучения для обучения модели нейронной сети	
Магистра	долматович А.С

Цель: обучить выбранную модель нейронной сети с помощью программных средств машинного обучения

Набор для обучения содержит 5000 изображений 20x20 в оттенках серого. Каждый пиксель представляет собой значение яркости (вещественное число). Каждое изображение сохранено в виде вектора из 400 элементов. Далее расположены метки классов изображений от 1 до 9 (соответствуют цифрам от 1 до 9), а также 10 соответствует цифре 0).

Топология модели (Персептрон)

- Вход 400
- Скрытый слой 25
- Выход 10

Демонстрационные примеры реализованных моделей и результатов их работы:

Инициализируем веса небольшими случайными числами

```
def generateWeights(shape):
    weights = []
    for i in range(shape[0]):
        line = []
        for j in range(shape[1]):
        value = random.random()
        line.append(value)
        weights.append(line)
    return np.array(weights)
```

Реализуем функцию распространения с сигмоидом в качестве функции активации

```
1 def sigmoid(x):
 2
      return 1 / (1 + np.exp(-x))
 3
 4 def getSigmoidData(ones, x, theta):
      if x.shape[1] != theta.shape[1]:
          x = np.hstack((ones, x))
 7
      z = np.dot(x, theta.T)
8
      return sigmoid(z)
10 def h(theta1, theta2, x):
m = len(x)
12
     ones = np.ones((m, 1))
13
     x = getSigmoidData(ones, x, thetal)
     return x, getSigmoidData(ones, x, theta2)
14
```

Реализуем функцию фычисления производной для функции активации

```
def sigmoidDerivate(x):
    return np.exp(-x) / ((1 + np.exp(-x)) ** 2)
```

Реализуем алгоритм обратного распространения ошибки

```
1 for j in xrange(100):
 2
       10 = x
       11, 12 = h(weights1, weights2, 10)
 3
       12error = y - 12
 4
 5
       if (j% 100) == 0:
           print "Error:" + str(np.mean(np.abs(12error)))
 6
 7
       12delta = 12error*sigmoidDerivate(12)
8
       llerror = 12delta.dot(weights2)
9
       lldelta = llerror * sigmoidDerivate(l1)
10
       weights1 += np.dot(10.T, 11delta).T
       weights2 += np.dot(11.T, 12delta).T
11
```

Значение параметра weights1, weights2:

```
[[-2.256228999-02 -1.056241630-08 2.19414684e-09 ... -1.30529929e-05 -5.04175101e-06 2.19464490-09] [-3.8811294e-02] 7.66168682-09 -9.75873689e-09 ... -5.60134007e-05 2.0051864e-09] 8.161376546e-09] 8.16137764e-09 ... -1.20951657e-04 -2.33669661e-06 -7.50668099e-09] [-3.25484493e-06] -7.50688099e-09] [-3.25484493e-06] 8.89272060e-09 -9.81968100e-09 ... -8.61759744e-04 9.43449909e-05 3.83761998e-09] [-3.25484493e-06] 9.0249960e-09] [-3.25484493e-06] 9.0249960e-09] [-3.2548493229e-0] 8.85876862e-09 -6.57515140e-10 ... -1.80365926e-06 -8.14464807e-06 8.79454531e-09] [-3.5093312e-01] 8.88976862e-09 -6.57515140e-10 ... -1.80365926e-06 -8.14464807e-06 8.79454531e-09] [-0.7610352 -1.1214498 -0.10187131] -2.36850085 -1.05778129 -2.20823629 [-0.7613628e] -1.152247 [-0.7610352 -1.1214498] -0.10175046 1.74825095 -0.2356648 -1.52014483 1.15324176 0.1036802 -0.37207719 -0.61530019 -0.1256836 -2.27193038 1.534618 0.036802 -0.37207719 -0.61530019 -0.1256836 -2.27193038 1.058389806 1.29520853 -1.56842397 -0.97026419 -2.18343495 -2.85933578 -2.07733086 1.63163164 0.3490229 1.82789117 -2.44174379 -0.8563034 -0.982564 -2.07947873 -1.2932338 0.8989203 0.238920578 2.31180525 -2.4644086 1.45656548] [-0.68934072 -1.94538151 2.01360618 -3.12316188 -0.2361763 1.38680947 0.90982429 -1.54774416 -0.79830896 -0.65599834 0.7353833 -2.58893294 0.47210839 0.55349499 2.51525453 -2.4167454 -1.65898627 1.0277302 -1.20245851 -1.83445959 -1.88013027 -0.3056098 0.23692483 -1.06137919 -0.40394736 1.80157527 -1.6774056 -1.98074099 0.17637699 -2.16141218 -0.68648661 -2.58273522 -0.47690832] [-0.67832479 0.46299226 0.58492321 -0.1650184 1.93264192 -0.22965765 -1.84731349 0.49114789 1.07593279 -0.23536089 -0.35894879 -0.08055871 -1.98074098 -0.2356648 -0.247413607 -0.2715545 -0.2742474 1.7559355 -0.2580899 -0.3586497 -0.3665871 -1.9950399 -0.25253004 0.23586497 -0.6665468 0.82467661] [-0.5766468 0.82467661] [-0.5766468 0.82467661] [-0.5766468 0.82467661] [-0.576648 0.82467661] [-0.576648 0.82467661] [-0.577668 0.82467661] [-0.576648 0.82467661] [-0.5766
```

Обучим нейронную сеть с помощью метода градиентного спуска

```
1  y = data["y"]
2  x = data["X"]
3  trainWeights1 = generateWeights((25, 401))
4  trainWeights2 = generateWeights((10, 26))
5  trainWeights = gradient([trainWeights1, trainWeights2], x, 0.0000001)
6  trainWeights1, trainWeights2 = trainWeights[0], trainWeights[1]
7  11, 12 = h(trainWeights1, trainWeights2, x)
```

Вычислим процент правильных классификаций на обучающей выборке (87.52)

```
def predictionPercentValue(resultLayer, y):
    predictions = np.argmax(resultLayer, axis=1) + 1
    predictionsCount = 0
    for predictionValue, realValue in zip(predictions, y):
        if predictionValue == realValue:
            predictionsCount += 1
    percentValue = float(predictionsCount) / len(y) * 100
    return percentValue
```

Ответы на вопросы.

Как были инициализированы весовые коэффициенты и влияют ли их начальные знаичения на результат обучения?

Весовые коэффициенты инициализированы случайными значениями близкими к нулю.

Как влияют параметры обучения на результат?

В зависимости от распределения случайной величины качество варьируется на 20-30%

Как зависит функция потерь от количества итераций?

С количеством итераций, функция потерь уменьшается

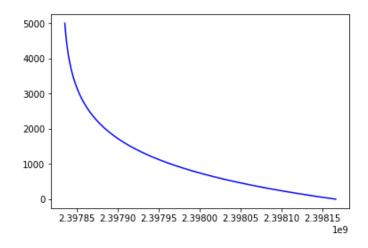


Рисунок 1 График функции потерь. Как видно с количеством итераций функция убывает

Каковы достигнутые полнота и точность классификации\распознавания или какова ошибка прогнозирования?

Используя алгоритм обратного распространения ошибки удалось достигнуть ошибки, равной 0.65

Заключение:

В лабораторной работе я качественно обучила нейронную сеть с помощью программных средств машинного обучения.

Список источников:

- [1] Nils J. Nilsson Introduction To Machine Learning // Stanford University, 1998.
- [2] Hal Daume A Course in Machine Learning // 2015.
- [3] D. Michie, D.J. Spiegelhalter, C.C. Taylor Machine Learning, Neural and Statistical Classication // 1994.
- [4] Max Kuhn, Kjell Johnson. Applied Predictive Modeling // Springer, 2013.
- [7] Andrew Ng http://www.mlyearning.org/