Лабораторная работа №5 “Метод опорных векторов”

Долатович Алина, 858461

Набор данных ex5data1.mat представляет собой файл формата *.mat (т.е. сохраненного из Matlab). Набор содержит три переменные X1 и X2 (независимые переменные) и y (метка класса). Данные являются линейно разделимыми.

Набор данных ex5data2.mat представляет собой файл формата *.mat (т.е. сохраненного из Matlab). Набор содержит три переменные X1 и X2 (независимые переменные) и y (метка класса). Данные являются нелинейно разделимыми.

Набор данных ex5data3.mat представляет собой файл формата *.mat (т.е. сохраненного из Matlab). Набор содержит три переменные X1 и X2 (независимые переменные) и y (метка класса). Данные разделены на две выборки: обучающая выборка (X, y), по которой определяются параметры модели; валидационная выборка (Xval, yval), на которой настраивается коэффициент регуляризации и параметры Гауссового ядра.

Набор данных spamTrain.mat представляет собой файл формата *.mat (т.е. сохраненного из Matlab). Набор содержит две переменные X - вектор, кодирующий отсутствие (0) или присутствие (1) слова из словаря vocab.txt в письме, и y - метка класса: 0 - не спам, 1 - спам. Набор используется для обучения классификатора.

Набор данных spamTest.mat представляет собой файл формата *.mat (т.е. сохраненного из Matlab). Набор содержит две переменные Xtest - вектор, кодирующий отсутствие (0) или присутствие (1) слова из словаря vocab.txt в письме, и ytest - метка класса: 0 - не спам, 1 - спам. Набор используется для проверки качества классификатора.

In [1]:
```
from scipy.io import loadmat
import matplotlib.pyplot as pyplot
from sklearn import svm
import numpy as np
import re
from nltk.stem import PorterStemmer
import pandas
import os
```

Загрузите данные ex5data1.mat из файла.

In [2]:
```
data = loadmat('ex5data1.mat')

x = data['X']
y = data['y']

print(x.shape)
print(y.shape)
```

```
(51, 2)
(51, 1)
```

Постройте график для загруженного набора данных: по осям - переменные X1, X2, а точки, принадлежащие различным классам должны быть обозначены различными маркерами.

In [3]:
```
def scatterPlot(x, y):
    pyplot.scatter(x[:, 0], x[:, 1], c=y.squeeze())

scatterPlot(x, y)
pyplot.show()
```

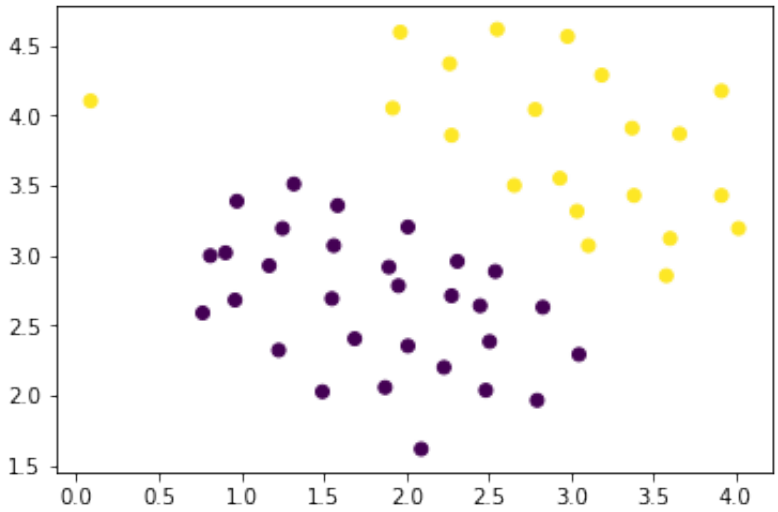

Обучите классификатор с помощью библиотечной реализации SVM с линейным ядром на данном наборе.

In [4]:
```
def getSVMModel(x, y, c=1, gamma=10, kernel='linear'):
    model = svm.SVC(kernel=kernel, C=c, gamma=gamma)
    model.fit(x, y.ravel())
    model.score(x, y.ravel())
    return model

svmModel = getSVMModel(x, y)
```

Постройте разделяющую прямую для классификаторов с различными параметрами C = 1, C = 100 (совместно с графиком из пункта 2). Объясните различия в полученных прямых?

In [5]:

```
def contourfPlot(x, y, svmModel, step=0.01):
    xMin, xMax = min(x[:, 0]) - 0.1, max(x[:, 0]) + 0.1
    yMin, yMax = min(x[:, 1]) - 0.1, max(x[:, 1]) + 0.1
    xx, yy = np.meshgrid(np.arange(xMin, xMax, step), np.arange(yM

    Z = svmModel.predict(np.c_[xx.ravel(), yy.ravel()])
    Z = Z.reshape(xx.shape)
    pyplot.contourf(xx, yy, Z)

def plotData(x, y, cs, kernel, gamma=10):
    for c in cs:
        svmModel = getSVMModel(x, y, c, gamma=gamma, kernel=kernel
        contourfPlot(x, y, svmModel)
        scatterPlot(x, y)
        pyplot.show()

cs = [1, 100]
plotData(x, y, cs, 'linear')
```

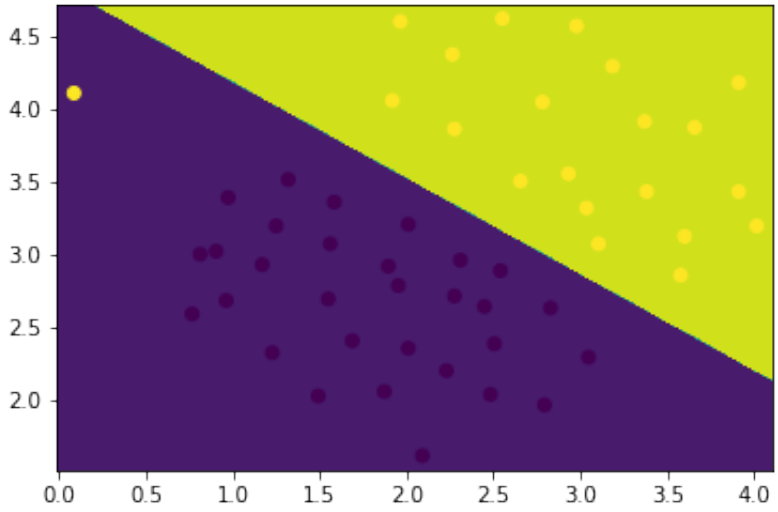

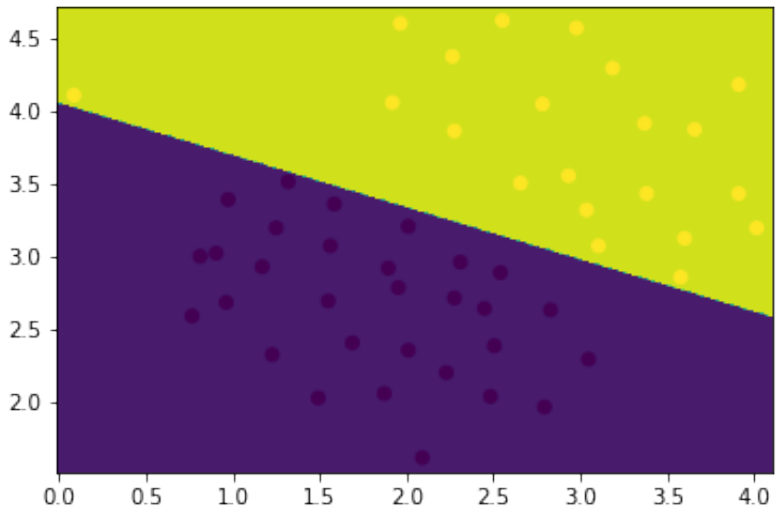

Реализуйте функцию вычисления Гауссового ядра для алгоритма SVM.

In [6]:
```
#k(x1,x2) = exp(-q * ||x1-x2||^2), q>0 \\ q=1/(2*sigm^2)

def gausKernel(x, gamma=0.5): #q>0
    x0, x1 = x[:, 0], x[:, 1]
    return np.exp(-gamma * max(x0 - x1) ** 2)

gausKernel(x)
```

Out[6]: 0.70966828666490156

Загрузите данные ex5data2.mat из файла.

In [7]:
```
data2 = loadmat('ex5data2.mat')

y = data2['y']
x = data2['X']

print(x.shape, y.shape)
```

```
((863, 2), (863, 1))
```

Обработайте данные с помощью функции Гауссового ядра.

In [8]:
```
width = gausKernel(x)
print(width)
```

```
0.844384016754
```

Обучите классификатор SVM.

In [9]:
```
svmModel = getSVMModel(x, y, gamma=width, kernel='rbf')
print(svmModel)
```

```
SVC(C=1, cache_size=200, class_weight=None, coef0=0.0,
  decision_function_shape='ovr', degree=3, gamma=0.84438401675358987
,
  kernel='rbf', max_iter=-1, probability=False, random_state=None,
  shrinking=True, tol=0.001, verbose=False)
```

Визуализируйте данные вместе с разделяющей кривой (аналогично пункту 4).

In [10]:
```
cs = [10, 100000]
plotData(x, y, cs, 'rbf', gamma=width)
```

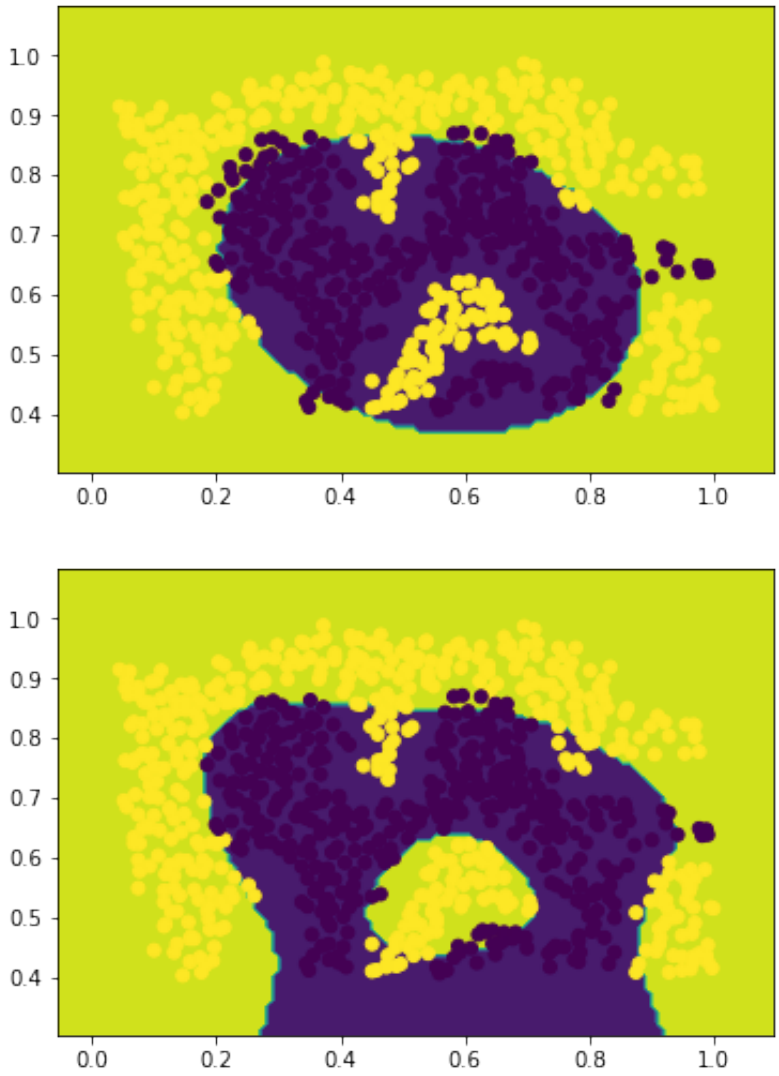

Загрузите данные ex5data3.mat из файла.

In [11]:
```
data3 = loadmat('ex5data3.mat')

yVal = data3['yval']
xVal = data3['Xval']

y = data3['y']
x = data3['X']

print(xVal.shape, yVal.shape, x.shape, y.shape)
```

```
((200, 2), (200, 1), (211, 2), (211, 1))
```

Вычислите параметры классификатора SVM на обучающей выборке, а также подберите параметры C и σ2 на валидационной выборке.

In [12]:
```
width = gausKernel(x)

model = getSVMModel(x, y, c=10000, gamma=width, kernel='rbf')
model.score(xVal, yVal)
params = model.get_params()
print(params)

predicted = model.predict(xVal)

errorCount = 0
for p, val in zip(predicted, yVal.squeeze()):
    if p != val:
        errorCount += 1

print(float(errorCount)/len(predicted))

```

```
{'kernel': 'rbf', 'C': 10000, 'verbose': False, 'probability': False
, 'degree': 3, 'shrinking': True, 'max_iter': -1, 'decision_function
_shape': 'ovr', 'random_state': None, 'tol': 0.001, 'cache_size': 20
0, 'coef0': 0.0, 'gamma': 0.77298573383986124, 'class_weight': None}
0.065
```

Визуализируйте данные вместе с разделяющей кривой (аналогично пункту 4).

In [13]:
```
cs = [100, 10000]
plotData(x, y, cs, 'rbf', gamma=width)

```

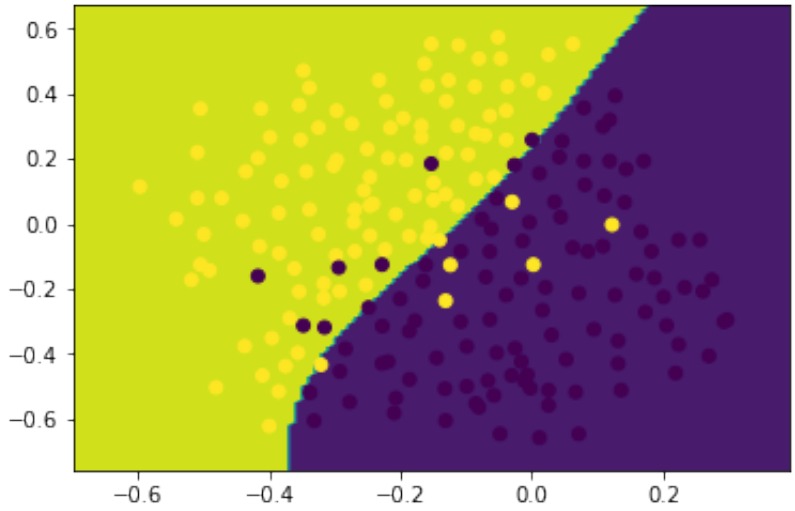

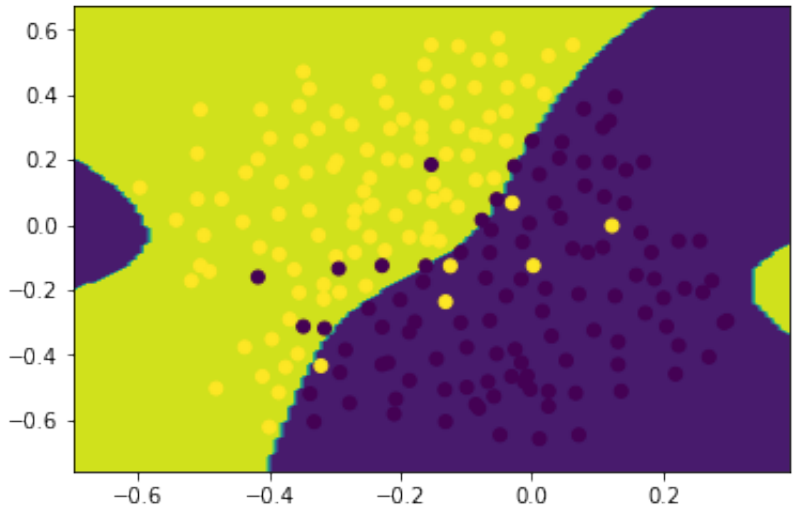

Загрузите данные spamTrain.mat из файла.

In [14]:
```
data4 = loadmat('spamTrain.mat')

trainX = data4['X']
trainY = data4['y']

print(trainX, trainY.shape)
```

```
(array([[0, 0, 0, ..., 0, 0, 0],
       [0, 0, 0, ..., 0, 0, 0],
       [0, 0, 0, ..., 0, 0, 0],
       ...,
       [0, 0, 0, ..., 0, 0, 0],
       [0, 0, 1, ..., 0, 0, 0],
       [0, 0, 0, ..., 0, 0, 0]], dtype=uint8), (4000, 1))
```

Обучите классификатор SVM.

In [15]:
```
model = getSVMModel(trainX, trainY, c=100, gamma=1, kernel='rbf')
print(model)
```

```
SVC(C=100, cache_size=200, class_weight=None, coef0=0.0,
  decision_function_shape='ovr', degree=3, gamma=1, kernel='rbf',
  max_iter=-1, probability=False, random_state=None, shrinking=True,
  tol=0.001, verbose=False)
```

Загрузите данные spamTest.mat из файла.

In [16]:
```
data5 = loadmat('spamTest.mat')

xTest = data5['Xtest']
yTest = data5['ytest']

print(xTest.shape, yTest.shape)
```

```
((1000, 1899), (1000, 1))
```

Подберите параметры C и σ2.

In [17]:
```
model.score(xTest, yTest)
```

Out[17]:
```
0.80900000000000005
```

In [18]:
```
1 emailText = open("emailSample1.txt", "r").read()
2 print(emailText)
```

```
> Anyone knows how much it costs to host a web portal ?
>
Well, it depends on how many visitors you're expecting.
This can be anywhere from less than 10 bucks a month to a couple of
$100.
You should checkout http://www.rackspace.com/
(http://www.rackspace.com/) or perhaps Amazon EC2
if youre running something big..

To unsubscribe yourself from this mailing list, send an email to:
groupname-unsubscribe@egroups.com
```

Реализуйте функцию предобработки текста письма, включающую в себя: -перевод в нижний регистр; -удаление HTML тэгов; -замена URL на одно слово (например, “httpaddr”); -замена email-адресов на одно слово (например, “emailaddr”); -замена чисел на одно слово (например, “number”); -замена знаков доллара ($) на слово “dollar”; -замена форм слов на исходное слово (например, слова “discount”, “discounts”, “discounted”, “discounting” должны быть заменены на слово “discount”). Такой подход называется stemming; -остальные символы должны быть удалены и заменены на пробелы, т.е. в результате получится текст, состоящий из слов, разделенных пробелами.

In [19]:
```
def processText(text):
    text = text.lower()

    htmlReg = r'<.*?>'
    text = re.sub(htmlReg, '', text)

    urlReg = r'[a-z]*[:.]+\S+'
    text = re.sub(urlReg, ' httpaddr ', text)

    emailReg = r'[\w\.-]+@[\w\.-]+'
    text = re.sub(emailReg, ' emailaddr ', text)

    numberReg = r'\d+'
    text = re.sub(numberReg, ' number ', text)

    text = text.replace('$', ' dollar ')

#     ps = PorterStemmer()
#     wordList = text.split(' ')
#     wordList = [ps.stem(w) for w in wordList]
#     text = ' '.join(wordList)

    symbolsReg = r'[?_()^@$%&*±>\/=<\t!@,.~\'|&\":;\\\n#$-]'
    text = re.sub(symbolsReg, '', text)
    return text

text = processText(emailText)
print(text)
```

```
 anyone knows how much it costs to host a web portal well it depends on how many visitors youre expectingthis can be anywhere from less than  number  bucks a month to a couple of  dollar  number  you should checkout  httpaddr  or perhaps amazon ec number  if youre running something  httpaddr to unsubscribe yourself from this mailing list send an email togroupnameunsubscribe httpaddr
```

Загрузите коды слов из словаря vocab.txt.

In [20]:
```
vocab = pandas.read_csv('vocab.txt', sep = "\t", header=None)
print(vocab.shape)
```

```
(1899, 2)
```

Реализуйте функцию замены слов в тексте письма после предобработки на их соответствующие коды.

In [21]:
```
def replaceWordToCode(text, vocab):
    wordsData = vocab[1]
    codesData = vocab[0]

    words = text.split(' ')
    codes = []
    for word in words:
        index = wordsData[wordsData == word].index.tolist()
        if index:
            code = codesData[index].values[0]
            codes.append(code)
    return codes

codes = replaceWordToCode(text, vocab)
print(codes)
```

```
[794, 1077, 883, 1699, 790, 1822, 1831, 883, 1171, 794, 238, 162, 68
8, 945, 1663, 1120, 1062, 1699, 1162, 477, 1120, 1893, 1510, 799, 11
82, 512, 1120, 810, 799, 1699, 1896, 688, 961, 1477, 71, 530, 799]
```

Реализуйте функцию преобразования текста письма в вектор признаков (в таком же формате как в файлах spamTrain.mat и spamTest.mat).

In [22]:
```
def conversion(codes, vocab):
    signs = np.zeros((len(vocab), len(codes)))
    for codeIndex in range(len(codes)):
        index = codes[codeIndex]
        signs[index-1, codeIndex] = 1
    return signs.T

conversionX = conversion(codes, vocab)
print(conversionX.shape)
```

```
(37, 1899)
```

Проверьте работу классификатора на письмах из файлов emailSample1.txt, emailSample2.txt, spamSample1.txt и spamSample2.txt.

In [23]:
```
def checkPredictedValue(vocab):
    mails = ['emailSample1.txt', 'emailSample2.txt', 'spamSample1.
    for mail in mails:
        emailText = open(mail, "r").read()
        text = processText(emailText)
        codes = replaceWordToCode(text, vocab)
        conversionX = conversion(codes, vocab)
#         print(conversionX)
        predicted = model.predict(conversionX)
        print(predicted)

checkPredictedValue(vocab)
```

```
[1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 0 1 1 1 1 0 1 1 1 1 1
1 1 0]
[1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 0 1 1
1 1 1
 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1
1 1 1
 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1
1 1 0
 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 0 0 1 0]
[1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1
1 1 1
 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1
1 1 1
 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1]
[1 1 1 1 1 1 1 1 1 1 1 1 1 1 0]
```

Создайте свой набор данных из оригинального корпуса текстов - http://spamassassin.apache.org/old/publiccorpus/ (http://spamassassin.apache.org/old/publiccorpus/).

In [24]:
```
def generateDict():
    paths = ['hard_ham/', 'spam/']
    keys = [0, 1]
    count = 0

    returnedText = ''
    dictValue = dict()
    for key, path in zip(keys, paths):
        fullText = ''
        for filename in os.listdir(path):
            fullText += open(path + filename, "r").read()

        fullText = processText(fullText)
        returnedText += fullText
        setWord = set(fullText.split(' '))
        for word in setWord:
            dictValue[count] = [count+1, word, key]
            count += 1

    return dictValue, returnedText

values, text = generateDict()
print(values)
```

```
IOPub data rate exceeded.
The notebook server will temporarily stop sending output
to the client in order to avoid crashing it.
To change this limit, set the config variable
`--NotebookApp.iopub_data_rate_limit`.
```

Постройте собственный словарь.

In [25]:
```
fullDict = pandas.DataFrame.from_dict(values, orient='index')
newVocab = fullDict.loc[:, fullDict.columns.isin([0, 1])]
newY = np.array(fullDict.loc[:, fullDict.columns.isin([2])])
xxx = list(fullDict.loc[:, fullDict.columns.isin([0])].values.sque
newX = conversion(xxx, newVocab)
```

In [ ]:
```
# codes = replaceWordToCode(text, newVocab)
```

In [ ]:
```
model = getSVMModel(newX, newY, c=100, gamma=1, kernel='rbf')
checkPredictedValue(newVocab)
```

Вывод

Метод опорных векторов — набор схожих алгоритмов обучения с учителем, использующихся для задач классификации и регрессионного анализа. Принадлежит семейству линейных классификаторов. Особым свойством метода опорных векторов является непрерывное уменьшение эмпирической ошибки классификации и увеличение зазора, поэтому метод также известен как метод классификатора с максимальным зазором.

Основная идея метода — перевод исходных векторов в пространство более высокой размерности и поиск разделяющей гиперплоскости с максимальным зазором в этом пространстве. Две параллельных гиперплоскости строятся по обеим сторонам гиперплоскости, разделяющей классы. Разделяющей гиперплоскостью будет гиперплоскость, максимизирующая расстояние до двух параллельных гиперплоскостей. Алгоритм работает в предположении, что чем больше разница или расстояние между этими параллельными гиперплоскостями, тем меньше будет средняя ошибка классификатора.