Лабораторная работа №8 “Выявление аномалий”

Долматович Алина, 858641

Набор данных ex8data1.mat представляет собой файл формата *.mat (т.е. сохраненного из Matlab). Набор содержит две переменные X1 и X2 - задержка в мс и пропускная способность в мб/с серверов. Среди серверов необходимо выделить те, характеристики которых аномальные. Набор разделен на обучающую выборку (X), которая не содержит меток классов, а также валидационную (Xval, yval), на которой необходимо оценить качество алгоритма выявления аномалий. В метках классов 0 обозначает отсутствие аномалии, а 1, соответственно, ее наличие.

Набор данных ex8data2.mat представляет собой файл формата *.mat (т.е. сохраненного из Matlab). Набор содержит 11-мерную переменную X - координаты точек, среди которых необходимо выделить аномальные. Набор разделен на обучающую выборку (X), которая не содержит меток классов, а также валидационную (Xval, yval), на которой необходимо оценить качество алгоритма выявления аномалий.

In [1]:
```
from scipy.io import loadmat
import matplotlib.pyplot as pyplot
import numpy as np
from scipy.stats import norm
import math
import seaborn as sns
```

Загрузите данные ex8data1.mat из файла.

In [2]:
```
data = loadmat('ex8data1.mat')

x = data['X']

xVal = data['Xval']
yVal = data['yval']

print(x.shape, xVal.shape, yVal.shape)
```

```
((307, 2), (307, 2), (307, 1))
```

Постройте график загруженных данных в виде диаграммы рассеяния.

In [3]:
```
pyplot.scatter(x[:, 0], x[:, 1])
pyplot.show()
```

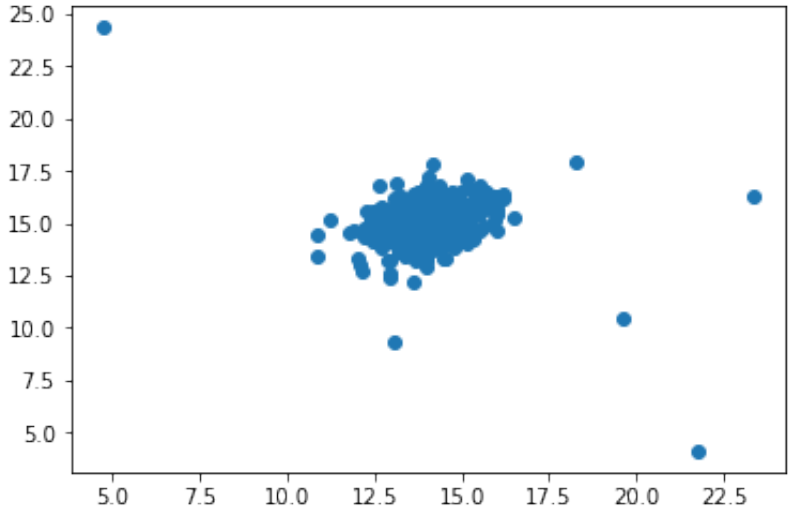

Представьте данные в виде двух независимых нормально распределенных случайных величин.

In [4]:
```
def normalTransform(x):
    normal = []
    for i in range(x.shape[1]):
        mu, sigma = norm.fit(x[:, i])
        value = 1 / math.sqrt(2 * math.pi * sigma ** 2) * math.e *
        normal.append(value)
    return np.array(normal).T

normalX = normalTransform(x)
print(normalX.shape)
```

```
(307, 2)
```

Оцените параметры распределений случайных величин.

In [5]:
```
def checkParameters(x):
    for i in range(x.shape[1]):
        mu, std = norm.fit(x[:, i])
        print(mu, std)

# checkParameters(x)
# checkParameters(normalX)
```

Постройте график плотности распределения получившейся случайной величины в виде изолиний, совместив его с графиком из пункта 2.

In [6]:
```
def densityPlot(x):
    with sns.axes_style('white'):
        sns.jointplot(x[:,0],x[:,1]).plot_joint(sns.kdeplot)

    pyplot.show()

densityPlot(normalX)
```

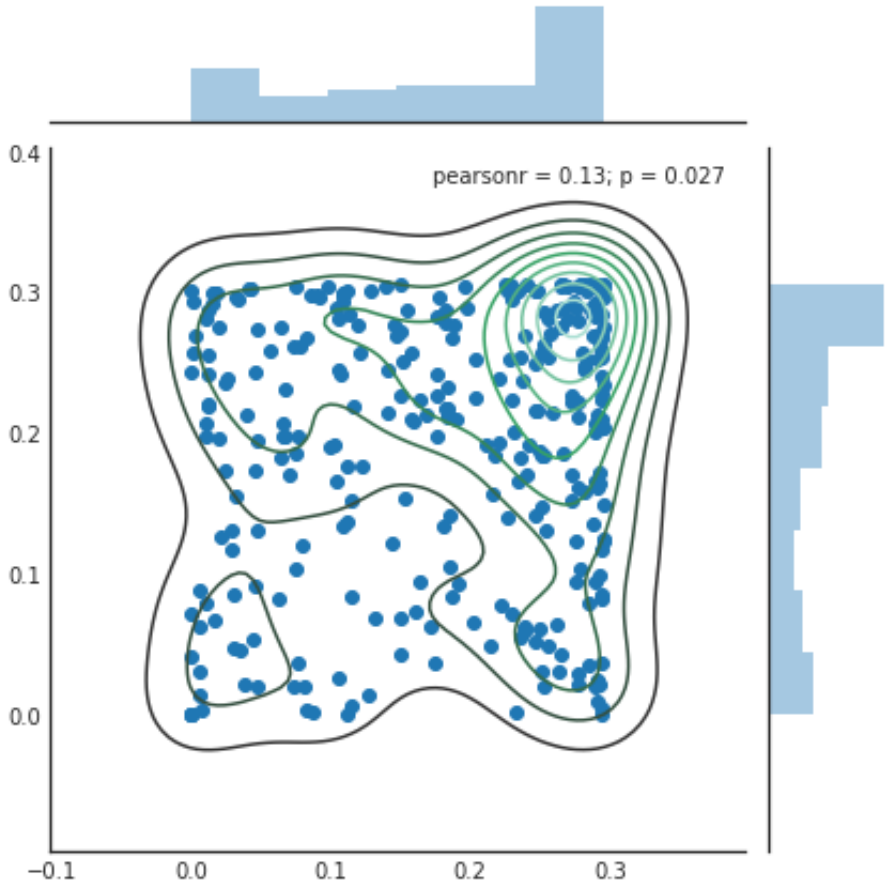

Подберите значение порога для обнаружения аномалий на основе валидационной выборки. В качестве метрики используйте F1-меру.

In [7]:
```
def f1Score(ypred, yact):
    tp, tn, fp, fn =0., 0., 0., 0.
    for yp,ya in zip(ypred, yact):
        if ya==1 and yp==1:
            tp+=1
        if ya==0 and yp==0:
            tn+=1
        if yp==0 and ya==1:
            fn+=1
        if yp==1 and ya==0:
            fp+=1
    precision = tp/(tp+fp)
    recall = tp/(tp+fn)
    f1 = 2 * (precision * recall) / (precision + recall)
    return f1
```

Выделите аномальные наблюдения на графике из пункта 5 с учетом выбранного порогового значения.

In [8]:
```
def zEvaluation(x, threshold=3.075):
    prediction = []
    rows, columns = x.shape

    for row in range(rows):
        for column in range(columns):
            mean = x[:, column].mean()
            std = x[:, column].std()
            if abs(x[row, column] - mean) / std > threshold:
                prediction.append(1)
                break
            if column == columns - 1:
                prediction.append(0)
    return np.array(prediction)

prediction = zEvaluation(xVal)
print(prediction.shape)
f1Score(prediction, yVal)

pyplot.scatter(xVal[:,0], xVal[:,1], c=prediction)
pyplot.show()
```

```
(307,)
```

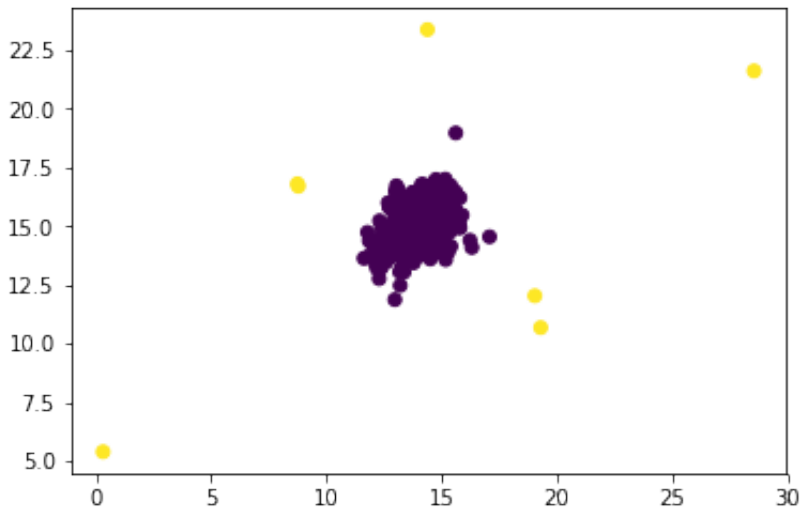

Загрузите данные ex8data2.mat из файла.

In [9]:
```
data2 = loadmat('ex8data2.mat')

x = data2['X']

xVal = data2['Xval']
yVal = data2['yval']

print(x.shape, xVal.shape, yVal.shape)
```

```
((1000, 11), (100, 11), (100, 1))
```

Представьте данные в виде 11-мерной нормально распределенной случайной величины.

In [10]:
```
normalX = normalTransform(x)
print(normalX.shape)
```

```
(1000, 11)
```

Оцените параметры распределения случайной величины.

In [11]:
```
# checkParameters(x)
# checkParameters(normalX)
```

Подберите значение порога для обнаружения аномалий на основе валидационной выборки. В качестве метрики используйте F1-меру.

In [12]:
```
threshold=3
prediction = zEvaluation(xVal, threshold)
f1Score(prediction, yVal)
```

Out[12]:
```
0.625
```

Выделите аномальные наблюдения в обучающей выборке. Сколько их было обнаружено? Какой был подобран порог?

In [13]:
```
1 pyplot.scatter(xVal[:,0], xVal[:,1], c=prediction)
2 pyplot.show()
```

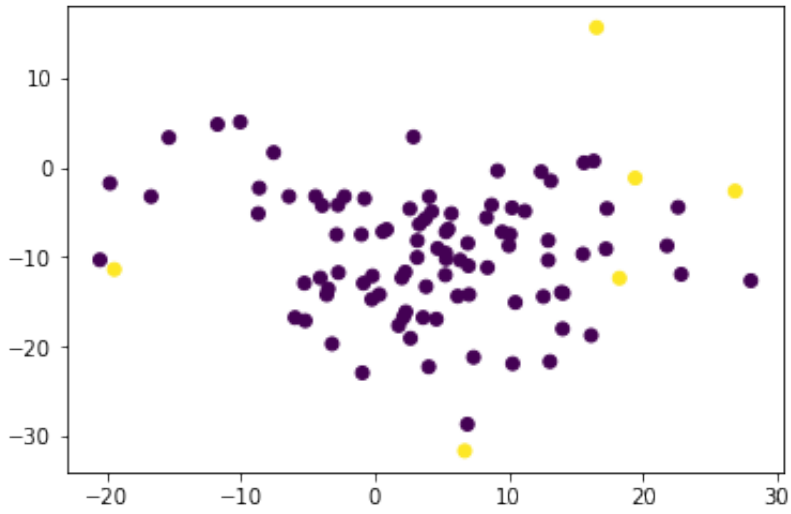

Вывод

Выявление аномалий (также обнаружение выбросов) — это опознавание во время интеллектуального анализа данных редких данных, событий или наблюдений, которые вызывают подозрения ввиду существенного отличия от большей части данных. Обычно аномальные данные превращаются в некоторый вид проблемы, такой как мошенничество в банке, структурный дефект, медицинские проблемы или ошибки в тексте. Аномалии также упоминаются как выбросы, необычности, шум, отклонения или исключения.